

Arquitecturas de Datos:

Data Lake vs. Data Warehouse

¿Por qué necesitamos una Arquitectura de Datos?

El fundamento de cualquier estrategia de datos moderna



Consolidar fuentes

Ordenar y unificar el gran número de fuentes de datos de origen dispares en un único ecosistema coherente.



Extraer información

Transformar los datos brutos en insights accionables que el negocio pueda leer, interpretar y explotar.



Tomar mejores decisiones

Disponer de datos fiables, actualizados y accesibles para fundamentar decisiones estratégicas con evidencia.

Cada arquitectura que veremos responde a estas tres necesidades de una forma diferente.

El pilar del BI Tradicional



Definición

Central de datos integrada, histórica y no volátil.
Almacena información altamente estructurada en tablas optimizadas para el análisis semántico.

¿Por qué surge?

Finales de los 80. Los equipos de BI ponían en peligro la estabilidad operativa al lanzar reportes pesados sobre bases de datos de producción. El DWH soluciona esto creando un entorno analítico completamente separado.

Enfoque de Negocio

BI clásico: reportes y dashboards para mirar al pasado. El Data Science quedaba fuera por la rigidez de los formatos.



Arquitectura Organizacional

Separación analítica del sistema de producción +
Centralización mediante ETL (lógica de negocio y limpieza).



Arquitectura Técnica (MPP)


Procesamiento Paralelo Masivo · Almacenamiento columnar ·
En la nube: proceso ELT (cargar primero, transformar después).

Ejemplos: Snowflake · Google BigQuery · Amazon Redshift

Doble Arquitectura del DWH


Arquitectura Organizacional — El proceso de negocio

- 1. Separación analítica:** Mueve los datos a un sistema físico separado para quitar carga a producción y aumentar el rendimiento del analytics.
- 2. Centralización ETL:** Extracción, Transformación (limpieza + lógica de negocio) y Carga para estructurar el modelo de datos.



Arquitectura Técnica — La infraestructura MPP


- 1. MPP:** Optimizado para escanear grandes volúmenes en paralelo con SQL de alto rendimiento.
- 2. Columnar + ELT:** Migró de filas a columnas para queries masivas rápidas. En la nube invierte el flujo a ELT.



Especialización para analistas de BI



Definición: Subconjunto especializado y refinado del DWH central. Nace porque los DWH corporativos se volvieron gigantescos e intimidantes; los analistas de Marketing no necesitan ver tablas de RRHH.



"Fundamentals of data engineering," Joe Reis & Matt Housley

¿Por qué surge?: Agilidad: datos pre-agregados listos para consumir, con mayor rendimiento que el DWH completo.

Proceso: Fase final del BI: transformaciones menores y joins complejos a partir del DWH global.

Ejemplo actual: Área de Finanzas en Snowflake conectada a un tablero de Power BI.

El nacimiento del Data Science masivo

"Guarda todo en bruto hoy, ya descubriremos su valor mañana."

Definición

Gran repositorio centralizado: estructurados, semiestructurados (JSON) y no estructurados (imágenes, audio, texto libre) a escala masiva y muy bajo coste.

Proceso: ELT


Extracción → Carga → Transformación. Datos sin modificar (Schema-on-Read). Transformación solo al momento del análisis, con Apache Spark.



✓ Masivo y barato ✓ Cualquier tipo de dato ✓ Ideal para ML

✗ Pantano de datos ✗ Complejo de operar ✗ Lento para SQL / GDPR difícil

Borrando la frontera entre BI y Data Science



Arquitectura híbrida: ACID + gobernanza del DWH sobre almacenamiento barato del Data Lake.

¿Por qué surge?: DWH + Data Lake en paralelo = doble coste, silos y 'pantanos'. GDPR imposible en lake puro.

Plataformas: Databricks · Microsoft Fabric

Tabla Comparativa

La evolución de las arquitecturas de datos: fortalezas, limitaciones y rol en la era moderna

Arquitectura	Ventajas clave	Desventajas	Rol actual
Data Warehouse	SQL ultra rápido · Alta calidad y gobernanza · Fácil para BI	Rígido ante cambios · Sin datos no estructurados · Almacenamiento costoso	Mirar al pasado (BI): Excelente para reportes, pero ciego ante ML.
Data Lake	Masivo y barato · Soporta cualquier tipo · Ideal para ML	Riesgo de pantano · Complejo de operar · Lento para SQL / GDPR	Mirar al futuro (Data Science): Laboratorio perfecto, pero aislado del negocio.
Data Mart	Consultas instantáneas · Datos pre-agregados · Fácil para usuarios de negocio	Visión parcial · Depende del DWH · No es independiente	Optimización BI departamental: capa de consumo rápido para analistas.
Data Lakehouse	Unifica BI y Data Science · ACID sobre almacenamiento barato · Compatible GDPR	Tecnología reciente · Requiere expertise técnico · Ecosistema en maduración	El presente y futuro: plataforma unificada para analistas y científicos de datos.